

# 实验一：模式识别系统设计

X

日期：July 15, 2022

## 摘 要

本实验为模式识别与深度学习课程的实验一：模式识别系统设计。按照前期拟定的主题，我们小组实现了一个关于遥感图像中的云和阴影检测的系统。具体而言，我们复现了一篇论文中所提出的 Cloud Net 结构，在 38 cloud 数据集上得到了 93.96 的准确率，并对比了 Cloud Net 与 FCN，UNet，SegNet 几种常用语义分割模型的效果。除此之外，我们对 Cloud Net 的结构做了一些改进，使其在充分训练后能够得到 95.26 的准确率。

**关键词：**模式识别，遥感图像，Cloud Net，38 cloud 数据集，云和阴影检测，语义分割

## 1 研究的目的及意义

### 1.1 选题原因

本次选题的灵感来源于小组成员个人的研究课题，小组成员参与了电子与信息工程学院测控工程的一个研究项目，主要关于遥感图像中的语义分割任务。因此想要以此为题目，结合在项目中的研究经验开发出一个模式识别系统。

### 1.2 已经具备的研究条件

- 阅读了遥感图像中语义分割任务相关的论文，了解了相关任务的常用方法与数据集。
- 了解了相关任务的近年发展情况，对任务难度进行了合理的评估。
- 找到了相关的遥感图像数据集（38 cloud dataset[1, 2]），准备开始论文复现。

### 1.3 研究目的与意义

近年来随着深度学习在图像处理领域的发展，其在不同领域的应用也得到了广泛关注，遥感图像处理就是其中热点应用方向之一。由于卫星遥感采用对地面俯拍的方式，成像面积常常可达到数十甚至数百公里，成像范围大，获取的地物信息多，如何从复杂的地物信息中快速精确的提取关注的目标是研究的热点问题。




图 1: 带有云层的遥感图像

而在从遥感图像中提取地面目标的过程中，云检测/阴影检测是一个必要的预处理环节。原因如下：

1. 由于云在地球表面广泛存在，往往遥感图像中的大量地表会被云层遮挡，造成地物信息的丢失。云的阴影所造成的影响相同
2. 云和阴影遮挡区域在大部分情况下产生了过多的无效图像数据，将其从卫星上传输到地面属于无效工作，影响了对后续目标检测的精度和速度。
3. 从另一方面来看，有时候云量本身可以提供有关气候参数和自然灾害 (如飓风和火山爆发) 的有用信息。某些时候，将云识别出来也可以更有针对性地反映有效信息。

因此，对遥感图像中的云层和阴影进行检测与识别，具有重要的现实意义与价值。

而随着深度学习技术的快速发展，运用深度神经网络进行语义分割，逐渐成为了进行云和阴影识别的主流方法。语义分割是计算机视觉中的基本任务，在语义分割中我们需要将视觉输入分为不同的语义可解释类别。在本实验中，我们便对比了近年来几种用于遥感图像语义分割的神经网络模型以及一篇论文中最新提出的 Cloud Net 的效果，并对 Cloud Net 的结构进行了改进，得到了一定的性能提升。

## 2 国内外相关研究现状分析

目前，云检测方法可大致分为三类：基于阈值的检测方法，基于纹理谱及其空间特征的检测方法，以及基于深度学习的检测方法，以下将依次介绍这几种检测方法的原理以及发展现状。

### 2.1 基于阈值的检测方法

近年来，基于阈值的检测方法主要有 [6, 10] 等。在 [10] 中，Zhu 等人引入了 Fmask(Function of mask) 算法。Fmask 基本由决策树组成，其首先使用基于云物理属性的规则来分离潜在云像素(PCP) 和清晰天空像素。接下来，将归一化温度概率、光谱可变性概率和亮度概率结合起来，分

别为陆地和水域上的云生成概率遮罩。然后，将 PCP 和云概率掩模一起用于推导潜在云层。由此，Fmask 算法通过多个阈值函数将潜在的云像素与非云像素进行分离。

而在 [6] 中，作者将数字高程图 (DEM) 信息集成到 Fmask 中，提高了 Fmask 在山区的性能表现。

基于阈值的检测方法可以展现出较好的性能。但该方法的缺点是对阈值的敏感程度较高，而且忽略了较多的空间信息，当部分像元被云覆盖时，容易产生误检。

## 2.2 基于纹理谱及其空间特征的检测方法

人们习惯把图像中局部不规则的、而宏观有规律的特性称之为纹理。与其他图像特征或描述相比，纹理性质似乎能更好的兼顾图像宏观性质与细部结构两个方面。为了定量的描述纹理，需要研究纹理本身可能具有的特征。多年来，人们建立了许多基于纹理谱的算法以测量纹理特征。Haze Optimized Transformation (HOT) [9] 是最著名的利用纹理谱的云识别算法。在该算法中，Zhang 等利用 Landsat 图像的两个光谱波段之间的相关性来区分薄云和清晰区域。总体而言，基于纹理谱的方法关键在于选择纹理特征，所选择的特征要精准反映云和地面的差异。但由于遥感影像中云的种类较多，所以仅利用纹理特征进行检测，效果提升有限。

## 2.3 基于深度学习的检测方法

近年来，基于深度学习的方法已被证明在许多图像处理应用中具有良好的性能。在遥感领域，也出现了许多深度学习算法的具体实践。例如，Xie 等人在 [8] 中利用两个卷积神经网络 (CNNs) 对图像进行语义分割，将图像中的子区域分类为厚云、薄云或非云类。除此之外，也能看到 UNet[7]，FCN[3] 等网络的应用。

而在论文 [5] 中，作者提出了一种新的云检测网络：Cloud Net。其中，专门设计了云网络的卷积块来捕捉遥感图像中云的复杂语义特征。其能够以端到端的方式从整个场景学习局部和全局特征，且不需要任何复杂的预处理步骤。我们后续的一大部分工作就是复现该论文的实现结果。

# 3 研究内容

## 3.1 研究内容

本次实验的主要内容就是设计一个关于遥感图像中的云和阴影检测的系统。具体而言，我们的工作分为几个部分：

1. 对数据集进行预处理，使之适合于 FCN 等模型的输入。
2. 测试 FCN，SegNet，UNet 三种模型在 38 cloud 数据集上的表现，做为本次实验的 baseline。
3. 复现论文 [5] 中的 Cloud Net 模型。
4. 对 [5] 中的 Cloud Net 模型进行进一步的改进，以提升模型在 38 cloud 数据集上的效果。

## 3.2 关键难点

本次实验的关键难点在于如何提高 Cloud Net 的性能表现。因为这涉及到对模型底层内容的修改，需要参考其他语义分割方面的最新成果，以提升模型性能。

## 4 技术方案与详细设计

本部分按照3.1的顺序，依次讲述每部分的具体实现以及技术参数。

### 4.1 数据集预处理

#### 4.1.1 数据集介绍

我们使用的数据集是 38 cloud dataset[1, 2]。其包含 18 张用于训练的 Landsat 8 卫星所拍摄的遥感图像，以及 20 张用于测试的遥感图像。由于遥感图像尺寸过大，在数据集中，将图像裁剪为了  $384 \times 384$  大小的小尺寸图片，最终得到 8400 张图片用于训练，9201 张图片用于测试。每张图片对应着 R,G,B,NIR 四个通道的数据，以及与之对应的 GT (groundtruth)，这些文件均是 TIF 数据格式。

#### 4.1.2 预处理

而由于 FCN, SegNet, UNet 对应的模型输入要求为一组训练图片 (PNG 格式，为 RGB 三通道) 与一组语义分割结果 (annotations)，因此，在数据结构方面出现了较大的差异，需要对 38-cloud 数据集进行一定处理才能输入模型进行训练。因此，需要对 38 cloud 数据集进行预处理。主要为以下两方面：

1. 将 TIF 格式图片转换为 PNG 格式 (对 R, G, B, NIR, GT 都进行转换)
2. 将 PNG 格式的 R, G, B 三通道图片合成为一张

在完成这两个步骤后，便得到了适应模型的输入。

对于 Cloud Net，由于论文的开源代码中包含了预处理部分的程序，因此不做额外的预处理。

### 4.2 构建 baseline

本次实验所采用的 baseline 为 FCN, SegNet, UNet 三种模型，这三种 baseline 采用 github 开源库 [keras-image-segmentation](#) 实现。在训练时，模型均采用默认参数。在 50 个 epoch 的充分训练后 (训练集和验证集损失趋于稳定)，我们得到了如下结果：

```
Epoch 48/50
512/512 [=====] - 22s 44ms/step - loss: 0.4833 - accuracy: 0.8106
saved 38-cloud dataset/processed/checkpoints/fcn_8.47
Epoch 49/50
512/512 [=====] - 22s 44ms/step - loss: 0.4795 - accuracy: 0.8114
saved 38-cloud dataset/processed/checkpoints/fcn_8.48
Epoch 50/50
512/512 [=====] - 22s 44ms/step - loss: 0.4859 - accuracy: 0.8123
```

图 2: FCN 训练结果



```

Epoch 48/50
512/512 [=====] - 13s 26ms/step - loss: 0.3646 - accuracy: 0.8722
saved 38-cloud dataset/processed/checkpoints/unet.47
Epoch 49/50
512/512 [=====] - 13s 26ms/step - loss: 0.3712 - accuracy: 0.8776
saved 38-cloud dataset/processed/checkpoints/unet.48
Epoch 50/50
512/512 [=====] - 13s 26ms/step - loss: 0.3912 - accuracy: 0.8610

```

图 3: UNet 训练结果

```

Epoch 48/50
512/512 [=====] - 12s 23ms/step - loss: 0.3878 - accuracy: 0.8634
saved 38-cloud dataset/processed/checkpoints/segnet.47
Epoch 49/50
512/512 [=====] - 12s 23ms/step - loss: 0.3930 - accuracy: 0.8697
saved 38-cloud dataset/processed/checkpoints/segnet.48
Epoch 50/50
512/512 [=====] - 12s 23ms/step - loss: 0.4101 - accuracy: 0.8571

```

图 4: SegNet 训练结果

通过上述实验可以看出，FCN，UNet，SegNet 均表现出了比较好的效果。其中，SegNet 和 UNet 最后的准确率在 86 左右，而 FCN 准确率稍低，只有 81 左右。

### 4.3 复现 Cloud Net 模型

在此部分，我们复现论文 [5] 中的网络结构。在论文中，对其网络结构的描述如下：




图 5: Cloud Net 网络结构

如图所示，Cloud Net 中有两个模块，一个负责收缩模型维度，从而提取并生成输入图像的深层底层特征，另一个负责扩张模型维度，从而放大特征并生成最终图像。

按照论文中的示意图，我们实现了 Cloud Net 的网络结构，并测试其在 38 cloud 数据集上的表现，最终，模型在该数据集上表现出了 93.96 的准确率，远超前面几种 baseline 模型。

以下是我们的训练结果：

Average evaluators over 20 scenes are:				
Precision,	Recall,	Specificity,	Jaccard,	Accuracy
87.504	, 76.737	, 98.192	, 71.831	, 93.965

图 6: Cloud Net 训练结果

#### 4.4 模型优化

通过阅读论文，我们发现在 [4] 中，基于 Cloud Net 的结构进行了进一步的修改，并取得了更好的效果。新的模型（名为“Cloud Net +”）由类似于 Cloud Net 中的 6 个“收缩块”和 5 个“扩展块”组成。为了减少参数，在新模型的最后两个收缩块和第一个扩展块中去除了 3\*3 的卷积层，并在所有收缩块的相邻 3\*3 卷积层之间添加了一个 1\*1 的卷积层。从而使得在参数量增加不多的情况下拓展了模型结构，从而使得模型可以更有效地检测云或阴影的边界。

新模型的结构如下：

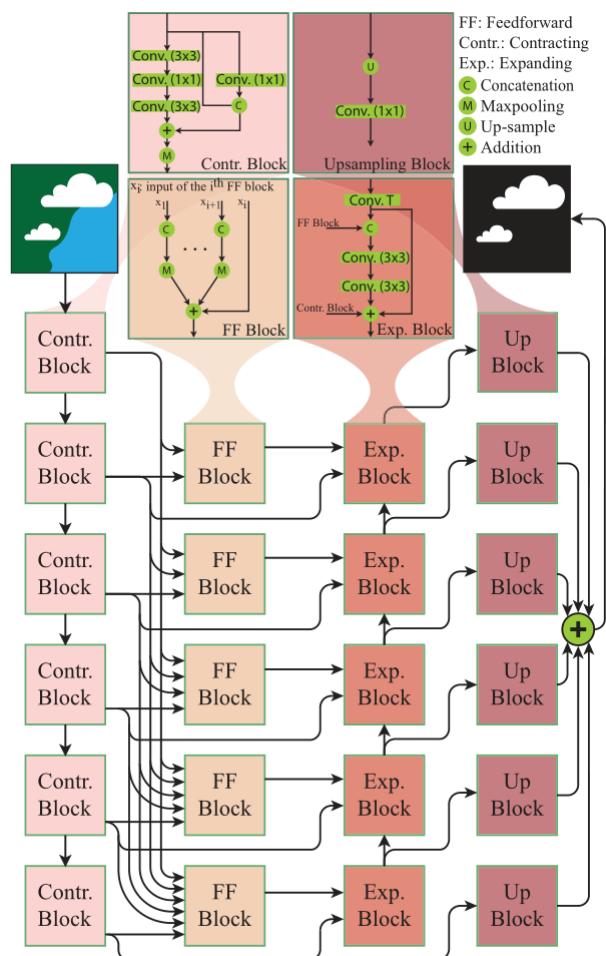


图 7: 新模型的网络结构

我们在飞桨 AI Studio 中部署了新构建的模型，训练过程如图所示，最终在模型 loss 稳定以后，我们得到了 95.26 的准确率，略高于原先的 Cloud Net。

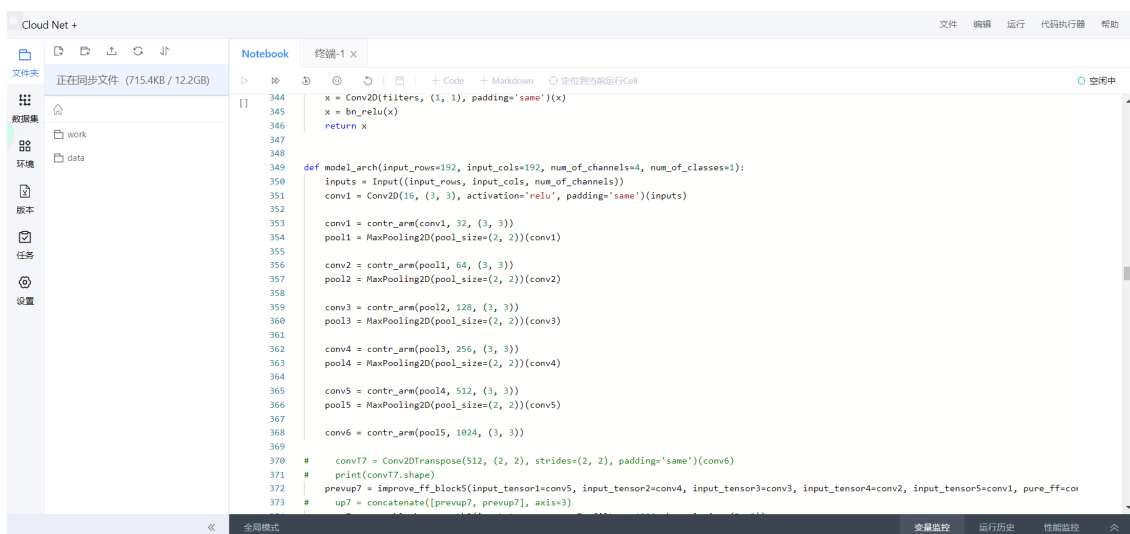


图 8: 飞桨平台代码示意

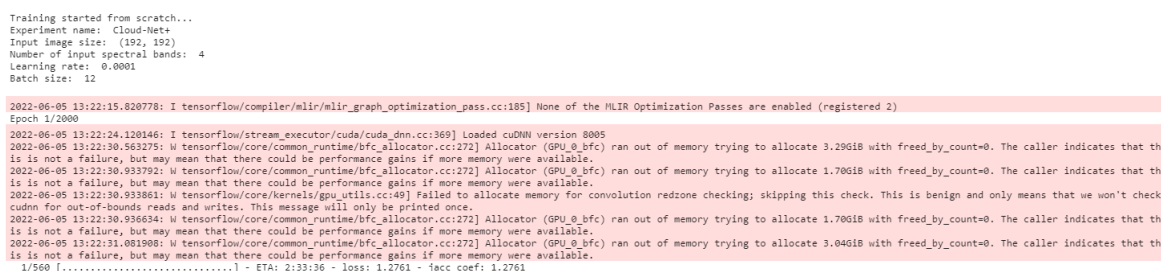


图 9: 飞桨平台训练过程

## 5 实验分析与结论

在三种 baseline 模型中，UNet 和 SegNet 的性能表现较好，不仅模型准确率较高，训练速度也比 FCN 要快很多。FCN 由于模型复杂度的原因，无论是训练速度还是准确率都不如前两者。

而 Cloud Net 的准确率则相较 3 种 baseline 模型有了明显提升。在对 Cloud Net 的结构进行微调后，我们得到了 95.26 的最高准确率。

以下是不同模型的具体评估数据对比：

表 1: 模型效果对比

Method	Precision	Recall	Accuracy
FCN	76.24	66.41	81.23
UNet	81.69	71.35	86.10
SegNet	79.63	72.80	85.71
Cloud Net	87.50	<b>76.74</b>	93.96
Cloud Net Plus	<b>90.39</b>	75.98	<b>95.26</b>

## 参考文献

- [1] S. Mohajerani, T. A. Krammer, and P. Saeedi. “A Cloud Detection Algorithm for Remote Sensing Images Using Fully Convolutional Neural Networks”. In: *2018 IEEE 20th International Workshop on Multimedia Signal Processing (MMSP)*. Aug. 2018, pp. 1–5.
- [2] S. Mohajerani and P. Saeedi. “Cloud-Net: An End-To-End Cloud Detection Algorithm for Landsat 8 Imagery”. In: *IGARSS 2019 - 2019 IEEE International Geoscience and Remote Sensing Symposium*. 2019, pp. 1029–1032.
- [3] Sorour Mohajerani, Thomas A Krammer, and Parvaneh Saeedi. “Cloud detection algorithm for remote sensing images using fully convolutional neural networks”. In: *arXiv preprint arXiv:1810.05782* (2018).
- [4] Sorour Mohajerani and Parvaneh Saeedi. “Cloud and Cloud Shadow Segmentation for Remote Sensing Imagery Via Filtered Jaccard Loss Function and Parametric Augmentation”. In: *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* (2021).
- [5] Sorour Mohajerani and Parvaneh Saeedi. “Cloud-Net: An end-to-end cloud detection algorithm for Landsat 8 imagery”. In: *IGARSS 2019-2019 IEEE International Geoscience and Remote Sensing Symposium*. IEEE. 2019, pp. 1029–1032.
- [6] Shi Qiu et al. “Improving Fmask cloud and cloud shadow detection in mountainous area for Landsats 4–8 images”. In: *Remote Sensing of Environment* 199 (2017), pp. 107–119.
- [7] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-net: Convolutional networks for biomedical image segmentation”. In: *International Conference on Medical image computing and computer-assisted intervention*. Springer. 2015, pp. 234–241.
- [8] Fengying Xie et al. “Multilevel cloud detection in remote sensing images based on deep learning”. In: *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 10.8 (2017), pp. 3631–3640.
- [9] Y Zhang, B Guindon, and J Cihlar. “An image transform to characterize and compensate for spatial variations in thin cloud contamination of Landsat images”. In: *Remote Sensing of Environment* 82.2 (2002), pp. 173–187.
- [10] Zhe Zhu and Curtis E. Woodcock. “Object-based cloud and cloud shadow detection in Landsat imagery”. In: *Remote Sensing of Environment* 118 (2012), pp. 83–94. ISSN: 0034-4257.